


Môn học: Khoa học dữ liệu

**Xây dựng mô hình phát hiện tin giả dựa trên
nội dung văn bản sử dụng Machine Learning**

22028279 - Nguyễn Đình Tuấn Anh
22028006 - Lê Việt Hoàng



Phát Hiện Tin Giả

Text Features + SBERT + XGBoost

Bài toán phân loại bài báo thành **Real** hoặc **Fake** — xây dựng pipeline hoàn chỉnh từ EDA, tiền xử lý, trích xuất đặc trưng, huấn luyện mô hình đến giải thích kết quả. Tin giả tác động trực tiếp đến niềm tin công chúng và khả năng ra quyết định dựa trên thông tin.

Tổng Quan Dataset

Dữ liệu được thu thập từ hai nguồn **True.csv** và **Fake.csv**, tạo thành bộ dữ liệu cân bằng với gần **44,898 mẫu**. Mỗi mẫu gồm bốn cột gốc: title, text, subject, date. Phân bố nhân tương đối cân bằng — đây là nền tảng quan trọng để đánh giá mô hình một cách công bằng và đáng tin cậy.

44,898

Tổng Mẫu Dữ Liệu

Tổng số bài báo trong toàn bộ dataset

23,481

Bài Fake

Chiếm ~52.3% tổng dataset

21,417


Bài Real

Chiếm ~47.7% tổng dataset

4

Cột Dữ Liệu Gốc

title, text, subject, date



EDA: Dữ Liệu Nói Gì?

Phân tích khám phá dữ liệu (EDA) giúp hiểu cấu trúc và phân bố của dữ liệu trước khi xây dựng mô hình. Qua các biểu đồ và trực quan hóa, ta có thể phát hiện các tín hiệu quan trọng từ cả **nội dung** lẫn **phong cách viết**.

Phân Phối Độ Dài Bài Báo


Phân tích `word_count` và `char_count` cho thấy bài Fake thường có xu hướng dài hơn và sử dụng nhiều từ cảm xúc hơn so với bài Real — đây là tín hiệu phân biệt quan trọng.

WordCloud — Từ Khóa Đặc Trưng

WordCloud của Fake và Real cho thấy sự khác biệt rõ rệt về từ vựng: bài Fake thường dùng ngôn ngữ giật gân, cảm tính; bài Real thiên về trung lập và sự kiện.

Tương Quan Meta-Features

`word_count` và `char_count` tương quan rất cao; trong khi `sentiment` gần như độc lập — cho thấy `sentiment` mang thông tin bổ sung riêng biệt, không trùng lặp với độ dài văn bản.



Tiền Xử Lý & Chống Leakage

⚠ Nguy Cơ Data Leakage

Cột subject chứa thông tin phân loại sẵn (ví dụ: "politics", "world news") — nếu dùng trực tiếp sẽ tạo leakage nghiêm trọng, khiến mô hình học "mẹo" thay vì học ngữ nghĩa thực sự.

- Loại bỏ hoàn toàn cột subject
- Chỉ dùng title + text làm đầu vào

Các Bước Làm Sạch Chính

- **Xóa dateline:** Loại bỏ mẫu "WASHINGTON (Reuters) — ..." ở đầu bài
- **Mask tên hãng tin:** Thay thế Reuters, AP, BBC... bằng token đặc biệt trong thân bài
- **Tạo 2 biến text:** clean_raw_text (giữ nguyên dấu câu, chữ hoa) và bert_text (làm sạch nhẹ cho SBERT)

Kỹ Thuật Tạo Đặc Trưng

Chiến lược đặc trưng kết hợp **ngữ nghĩa sâu** từ embedding với **dấu hiệu hình thức** từ meta-features — tạo ra biểu diễn đa chiều, giàu thông tin cho mô hình học máy.

- | | |
|---|--|
| 1 | char_count
Tổng số ký tự trong bài — phản ánh độ dài tổng thể |
| 2 | word_count
Tổng số từ — bài Fake thường dài hơn và lan man hơn |
| 3 | capital_ratio
Tỷ lệ chữ HOA — tín hiệu của ngôn ngữ giật gân, cảm xúc mạnh |
| 4 | punctuation_ratio
Tỷ lệ dấu câu — bài Fake thường dùng nhiều dấu chấm than (!!!) |
| 5 | sentiment
Điểm cảm xúc (âm/dương/trung tính) — bài Fake thường cực đoan hơn |

📌 5 meta-features được ghép nối với 384 chiều embedding từ SBERT, tạo vector đầu vào **389 chiều** — kết hợp cả ngữ nghĩa lẫn phong cách viết.

Kiến Trúc Mô Hình

Pipeline được thiết kế theo luồng xử lý tuần tự: từ văn bản thô đến embedding ngữ nghĩa, kết hợp với meta-features, và cuối cùng là mô hình phân lớp mạnh mẽ. Mỗi bước được tối ưu để phát huy điểm mạnh của từng thành phần.



Mô hình **Sentence-BERT (all-MiniLM-L6-v2)** được chọn vì cân bằng tốt giữa tốc độ và chất lượng — tạo vector 384 chiều giàu ngữ nghĩa. **ColumnTransformer** xử lý riêng biệt hai loại đặc trưng: embedding giữ nguyên, meta-features được chuẩn hóa MinMaxScaler. Cuối cùng, **XGBoost** học các mẫu phi tuyến phức tạp trong không gian 389 chiều.

So Sánh Baseline & Mô Hình Cuối

Ba mô hình được đánh giá để chứng minh hiệu quả của phương pháp đề xuất. Việc so sánh với baseline giúp xác nhận rằng sự phức tạp thêm vào là xứng đáng và mang lại cải thiện thực chất.

Baseline 1: Logistic Regression

Mô hình tuyến tính đơn giản, dễ giải thích.
Hiệu năng cơ bản, khó bắt các mẫu phi tuyến trong không gian embedding nhiều chiều.

Baseline 2: Random Forest

Ensemble cây quyết định, xử lý tốt dữ liệu phi tuyến. Tuy nhiên, kém hiệu quả hơn trong không gian đặc trưng rất nhiều chiều như embedding.

✅ Final: XGBoost

Gradient boosting tối ưu — bắt quan hệ phi tuyến xuất sắc, làm việc hiệu quả với 389 chiều đặc trưng, và thường vượt trội so với cả hai baseline trên dữ liệu văn bản.

Kết Quả Đánh Giá Mô Hình

Chỉ Số Hiệu Năng Chính

Mô hình XGBoost cuối cùng đạt **accuracy ~95.98%** — kết quả ấn tượng, vượt 5-15% so với các mô hình baseline. Tuy nhiên, cần đánh giá toàn diện qua nhiều chỉ số:

Accuracy

Tỷ lệ dự đoán đúng tổng thể

Precision & Recall

Độ chính xác và độ phủ cho từng lớp

F1-Score

Trung bình điều hòa — cân bằng Precision/Recall

Confusion Matrix

Phân tích ma trận nhầm lẫn giúp hiểu **loại lỗi nào nguy hiểm hơn**:

- **Fake → Real**: Tin giả lọt qua — rủi ro cao nhất
- **Real → Fake**: Tin thật bị chặn — gây mất niềm tin

Trong thực tế, cần ưu tiên **giảm thiểu False Negative** (Fake bị phân loại nhầm thành Real).

Giải Thích, Hạn Chế & Kết Luận

🔍 SHAP — Giải Thích Mô Hình

SHAP (SHapley Additive exPlanations) giúp xác định feature nào ảnh hưởng mạnh nhất đến quyết định. Kết quả cho thấy **meta-features** có **giá trị hỗ trợ thực sự** — không chỉ dựa vào embedding ngữ nghĩa.

⚠️ Hạn Chế Cần Lưu Ý

- Dữ liệu cùng nguồn/cùng giai đoạn — khả năng tổng quát hóa chưa được kiểm chứng đầy đủ
- Chưa tích hợp metadata: nguồn tin, tác giả, hình ảnh đính kèm
- Data augmentation chỉ áp dụng một phần tập train

✅ Kết Luận

Pipeline kết hợp **EDA** → **Cleaning** → **Feature Engineering** → **SBERT** → **XGBoost** là một phương pháp hợp lý, có cấu trúc rõ ràng và đạt hiệu quả rất cao.

Hướng Phát Triển Tiếp Theo

- Thử nghiệm trên dataset đa nguồn, đa ngôn ngữ
- Tích hợp thêm metadata và phân tích hình ảnh
- Triển khai real-time detection API
- Áp dụng LLM để giải thích lý do phân loại

