

Tổng Quan Dataset

Dữ liệu được thu thập từ hai nguồn **True.csv** và **Fake.csv**, tạo thành bộ dữ liệu cân bằng với gần **44,898 mẫu**. Mỗi mẫu gồm bốn cột gốc: **title**, **text**, **subject**, **date**. Phân bổ nhãn tương đối cân bằng – đây là nền tảng quan trọng để đánh giá mô hình một cách công bằng và đáng tin cậy.

44,898

Tổng Mẫu Dữ Liệu

Tổng số bài báo trong toàn bộ dataset

23,481

Bài Fake

Chiếm ~52.3% tổng dataset

21,417

Bài Real


Chiếm ~47.7% tổng dataset

4

Cột Dữ Liệu Gốc

title, text, subject, date

Spneults	B	D	A
ws llardlens	News	8%	18%
gke; deberterils	50		5%
loradlghedoahnsnpiion	8%		um
rgardlone stuleries	5503/62	or	tm
oce Caslavins	50		mn
opibeas Rageobinen	00		oo
oe lnacheious Conay	Loose.ch		um
rtlers inlnaccs joaslov	65729		6rc
ghofcah baHl leting	50195		im
hamolly Boreinays	60		sio
sealotle Reskatibss	46%		1Slp
Gsulavy Euahcars	73188		1rm
ninetee Sparrey	A382		sip
resrnelskipaises	Flensiporis		Sp
rtiers; Meavedanohtuts		3%	492
isclncting Smlarad			so
srtss lkoalibtr:lacty chess	220nteilt		Sg
erdlors Turnoa Tionrnib	Sease		so
ns. lhpeta Neglneiara	737695	108	Slo
rties lRooaaleoshesterge s			Sio
aaloiockabession	60%		6io
anineabuiocs Scoobson	30%		1re
sehestaon Peastimt	610%		tin
Hiaatlptetake Caetlcal gly	204%	11	1o
srtatnainvaris atedh, ictetst	602%		1re
Recipot d:arastbaks	332%		tns
Gaaestorts lnohaals.	48192		trq
iestleucom hcl serskips ars, Obhcs	244235		Sg
ation Dhsacaiods	488%		Sio
ana to Hatirlcach	463%		op
lccdan Bosthielk	092%		Sio
nts ttahdonteofhtereet	488%		un
loesfion hdepestiole	493%		Sio



EDA: Dữ Liệu Nói Gì?

Phân tích khám phá dữ liệu (EDA) giúp hiểu cấu trúc và phân bố của dữ liệu trước khi xây dựng mô hình. Qua các biểu đồ và trực quan hóa, ta có thể phát hiện các tín hiệu quan trọng từ cả **nội dung** lẫn **phong cách viết**.



Phân Phối Độ Dài Bài Báo

Phân tích `word_count` và `char_count` cho thấy bài Fake thường có xu hướng dài hơn và sử dụng nhiều từ cảm xúc hơn so với bài Real – đây là tín hiệu phân biệt quan trọng.



WordCloud — Từ Khóa Đặc Trưng

WordCloud của Fake và Real cho thấy sự khác biệt rõ rệt về từ vựng: bài Fake thường dùng ngôn ngữ giật gân, cảm tính; bài Real thiên về trung lập và sự kiện.



Tương Quan Meta-Features

`word_count` và `char_count` tương quan rất cao; trong khi `sentiment` gần như độc lập – cho thấy `sentiment` mang thông tin bổ sung riêng biệt, không trùng lặp với độ dài văn bản.

Tiền Xử Lý & Chống Leakage

⚠ Nguy Cơ Data Leakage

Cột `subject` chứa thông tin phân loại sẵn (ví dụ: "politics", "world news") – nếu dùng trực tiếp sẽ tạo leakage nghiêm trọng, khiến mô hình học "mẹo" thay vì học ngữ nghĩa thực sự.

- Loại bỏ hoàn toàn cột `subject`
- Chỉ dùng `title + text` làm đầu vào

Các Bước Làm Sạch Chính

- Xóa dateline:** Loại bỏ mẫu "*WASHINGTON (Reuters) – ...*" ở đầu bài
- Mask tên hãng tin:** Thay thế Reuters, AP, BBC... bằng token đặc biệt trong thân bài
- Tạo 2 biến text:** `clean_raw_text` (giữ nguyên dấu câu, chữ hoa) và `bert_text` (làm sạch nhẹ cho SBERT)

Kỹ Thuật Tạo Đặc Trưng

Chiến lược đặc trưng kết hợp **ngữ nghĩa sâu** từ embedding với **dấu hiệu hình thức** từ meta-features – tạo ra biểu diễn đa chiều, giàu thông tin cho mô hình học máy.

1

char_count

Tổng số ký tự trong bài – phản ánh độ dài tổng thể

2

word_count

Tổng số từ – bài Fake thường dài hơn và lan man hơn

3

capital_ratio

Tỷ lệ chữ HOA – tín hiệu của ngôn ngữ giật gân, cảm xúc mạnh

4

punctuation_ratio

Tỷ lệ dấu câu – bài Fake thường dùng nhiều dấu chấm than (!!!)

5


sentiment

Điểm cảm xúc (âm/dương/trung tính) – bài Fake thường cực đoan hơn

📌 5 meta-features được ghép nối với 384 chiều embedding từ SBERT, tạo vector đầu vào **389 chiều** – kết hợp cả ngữ nghĩa lẫn phong cách viết.

Kiến Trúc Mô Hình

Pipeline được thiết kế theo luồng xử lý tuần tự: từ văn bản thô đến embedding ngữ nghĩa, kết hợp với meta-features, và cuối cùng là mô hình phân lớp mạnh mẽ. Mỗi bước được tối ưu để phát huy điểm mạnh của từng thành phần.



Văn bản đầu vào

Sentence-BERT

ColumnTransformer

XGBoost

Mô hình **Sentence-BERT (all-MiniLM-L6-v2)** được chọn vì cân bằng tốt giữa tốc độ và chất lượng – tạo vector 384 chiều giàu ngữ nghĩa. **ColumnTransformer** xử lý riêng biệt hai loại đặc trưng: embedding giữ nguyên, meta-features được chuẩn hóa MinMaxScaler. Cuối cùng, **XGBoost** học các mẫu phi tuyến phức tạp trong không gian 389 chiều.

So Sánh Baseline & Mô Hình Cuối

Ba mô hình được đánh giá để chứng minh hiệu quả của phương pháp đề xuất. Việc so sánh với baseline giúp xác nhận rằng sự phức tạp thêm vào là xứng đáng và mang lại cải thiện thực chất.

Baseline 1: Logistic Regression

Mô hình tuyến tính đơn giản, dễ giải thích. Hiệu năng cơ bản, khó bắt các mẫu phi tuyến trong không gian embedding nhiều chiều.

Baseline 2: Random Forest

Ensemble cây quyết định, xử lý tốt dữ liệu phi tuyến. Tuy nhiên, kém hiệu quả hơn trong không gian đặc trưng rất nhiều chiều như embedding.

✓ Final: XGBoost

Gradient boosting tối ưu – bắt quan hệ phi tuyến xuất sắc, làm việc hiệu quả với 389 chiều đặc trưng, và thường vượt trội so với cả hai baseline trên dữ liệu văn bản.

Kết Quả Đánh Giá Mô Hình

Chỉ Số Hiệu Năng Chính

Mô hình XGBoost cuối cùng đạt **accuracy ~99.21%** – kết quả rất ấn tượng. Tuy nhiên, cần đánh giá toàn diện qua nhiều chỉ số:

Accuracy

Tỷ lệ dự đoán đúng tổng thể

Precision & Recall

Độ chính xác và độ phủ cho từng lớp

F1-Score

Trung bình điều hòa – cân bằng Precision/Recall

Confusion Matrix

Phân tích ma trận nhầm lẫn giúp hiểu **loại lỗi nào nguy hiểm hơn**:

- **Fake → Real:** Tin giả lọt qua – rủi ro cao nhất
- **Real → Fake:** Tin thật bị chặn – gây mất niềm tin

Trong thực tế, cần ưu tiên **giảm thiểu False Negative** (Fake bị phân loại nhầm thành Real).

Giải Thích, Hạn Chế & Kết Luận

SHAP — Giải Thích Mô Hình

SHAP (SHapley Additive exPlanations) giúp xác định feature nào ảnh hưởng mạnh nhất đến quyết định. Kết quả cho thấy **meta-features có giá trị hỗ trợ thực sự** – không chỉ dựa vào embedding ngữ nghĩa.

Hạn Chế Cần Lưu Ý

- Dữ liệu cùng nguồn/cùng giai đoạn – khả năng tổng quát hóa chưa được kiểm chứng đầy đủ
- Chưa tích hợp metadata: nguồn tin, tác giả, hình ảnh đính kèm
- Data augmentation chỉ áp dụng một phần tập train

Kết Luận

Pipeline kết hợp **EDA → Cleaning → Feature Engineering → SBERT → XGBoost** là một phương pháp hợp lý, có cấu trúc rõ ràng và đạt hiệu quả rất cao.

Hướng Phát Triển Tiếp Theo

- Thử nghiệm trên dataset đa nguồn, đa ngôn ngữ
- Tích hợp thêm metadata và phân tích hình ảnh
- Triển khai real-time detection API
- Áp dụng LLM để giải thích lý do phân loại